

Projet 9 — Détection de phishing (emails et sites frauduleux)

Secteur: Banque · Assurance · Toute entreprise avec des employés connectés

Problématique: Comment une IA peut-elle apprendre à reconnaître un faux email mieux qu'un humain pressé ?

Contexte et problématique

Le phishing — envoyer un faux email ou créer un faux site web pour voler des mots de passe ou des informations bancaires — représente 90 % des portes d'entrée des cyberattaques en entreprise. Les filtres anti-spam classiques ne suffisent plus face aux attaques de plus en plus sophistiquées. L'idée de ce projet : créer un système intelligent qui analyse un email ou une URL et dit immédiatement si c'est du phishing ou non — et surtout, qui explique pourquoi.

Ce que l'équipe va construire

Votre équipe va construire un détecteur de phishing en deux modules indépendants. Le premier analyse le texte de l'email : vous transformez le contenu en vecteur numérique avec TF-IDF, puis vous entraînez une Régression Logistique ou un Naive Bayes pour classer l'email. Le deuxième module analyse l'URL : vous calculerez des caractéristiques simples (longueur de l'URL, nombre de chiffres, présence de mots suspects). Les deux scores sont combinés pour donner un verdict final. La démonstration est la partie la plus fun : l'utilisateur colle un email dans l'interface, clique sur « Analyser », et voit s'afficher le verdict avec les mots suspects surlignés en rouge.

Rôles par filière

- **L1/L2 IA:** vectoriser les emails avec TF-IDF, entraîner le classifieur (Naive Bayes ou Régression Logistique), coder l'analyseur d'URL (calcul des features), combiner les deux scores, afficher les mots les plus influents.
- **L1/L2 Cyber :** rédiger des emails de phishing réalistes pour tester le modèle, expliquer les techniques d'ingénierie sociale au jury, analyser les protocoles SPF/DKIM, définir la procédure à suivre quand un phishing est détecté.
- **IAGE :** construire l'interface de saisie : champ pour coller l'email, bouton « Analyser », affichage du verdict avec les mots suspects surlignés, tableau de bord de suivi des incidents pour un responsable sécurité.

- **Maths Info.** : calculer l'entropie des URLs (mesure du désordre dans les caractères), concevoir les features lexicales, optimiser le seuil de décision, comparer les deux classifieurs.
- **MOSIEF** : estimer le coût moyen d'une attaque phishing réussie en entreprise, calculer le taux de réduction du risque avec le système, modéliser l'impact assurantiel.

Outils et technologies utilisés

Python, Scikit-learn, NLTK, Pandas, Streamlit, WordCloud. Tout est gratuit.

Données de travail : SpamAssassin Public Corpus (des milliers d'emails étiquetés spam/ham, téléchargeable gratuitement) + PhishTank (base d'URLs de phishing vérifiées, accès gratuit).